

Penerjemah Bahasa Isyarat Dasar Berbasis Web Menggunakan Deep Learning AI dan Deterministic Finite Automata

Farid Fathurrahman Hakim, Faza Adriana Putra, Firda Azzahra, Ghevrya Nur Fadilah, Hafizh Maulana Praditya, Muhammad Zadit Taqwa Indana Zulva
Program Studi Informatika, UIN Sunan Gunung Djati Bandung, Indonesia

Info Artikel

Riwayat artikel:

Diterima 11 Desember 2025

Direvisi -

Diterima -

Kata kunci:

Deep Learning
American Sign Language
Penerjemah Bahasa Isyarat
Deterministic Finite Automata
Artificial intelligence

ABSTRAK

Kesenjangan komunikasi antara komunitas tuli dan masyarakat umum memicu kebutuhan mendesak akan sistem penerjemah bahasa isyarat yang mampu menjembatani kesenjangan ini. Penerjemah Bahasa Isyarat Dasar American Sign Language (ASL) Berbasis Web yang mengintegrasikan Deep Learning Multilayer Perceptron (MLP) dengan Deterministic Finite Automata (DFA) dapat menjadi solusi. Sistem ini menggunakan Computer Vision (MediaPipe) untuk dianotasikan dengan 21 titik kunci (*keypoints*), yang kemudian diumpankan ke model MLP untuk klasifikasi huruf (A-Z) dan angka (0-9). Meskipun MLP mencapai akurasi klasifikasi frame baik, outputnya rentan terhadap ketidakstabilan (*flickering*). Untuk mengatasi masalah ini, DFA diimplementasikan sebagai lapisan logika *post-processing*. DFA bertindak sebagai *validator state* yang hanya mencetak huruf ke output jika prediksi MLP stabil selama *threshold* waktu tertentu dan urutan ejaan kata (*fingerspelling*) valid sesuai kaidah bahasa. Implementasi sistem berbasis web memungkinkan pengguna untuk mengakses layanan penerjemah bahasa isyarat langsung melalui *browser* di berbagai perangkat

Korespondensi Penulis:

faridhakim1234a@gmail.com

Program Studi Informatika, Fakultas Sains dan Teknologi, UIN Sunan Gunung Djati Bandung

Jl. A. H. Nasution No. 105, Cibiru, Bandung, Indonesia. 40614

Email: join@uinsgd.ac.id

1. PENDAHULUAN

Komunikasi adalah hak dasar setiap manusia, namun bagi komunitas Tuli, keterbatasan akses terhadap bahasa lisan seringkali menjadi penghambat dalam partisipasi sosial. Bahasa isyarat menjadi medium penting untuk menjembatani kesenjangan ini [1]. American Sign Language (ASL) adalah bahasa isyarat yang digunakan secara luas oleh komunitas Tuli di Amerika Serikat dan di hampir digunakan di berbagai negara di seluruh dunia. Melalui ASL, komunitas Tuli bisa mengembangkan kemampuan bahasa, berinteraksi sosial, dan inklusi dalam lingkungan pendidikan maupun profesional [2]. Pengembangan sistem penerjemah bahasa isyarat berbasis teknologi Computer Vision dapat membantu menjembatani kesenjangan komunikasi ini dan memperluas inklusi sosial [3].

Perkembangan kecerdasan buatan, khususnya Deep Learning, telah menunjukkan kemajuan pesat, dimana terbukti efektif untuk pengenalan gerakan tangan dan klasifikasi citra, termasuk pengenalan alfabet dan kata dalam bahasa isyarat. Penerapan Multilayer Perceptron (MLP) pada pengenalan bahasa isyarat dilakukan dengan memanfaatkan fitur-fitur yang berasal dari representasi geometri tangan, digunakan untuk mempelajari pola hubungan antar titik tersebut dan menghasilkan klasifikasi *gesture* tertentu dengan akurasi yang baik [4]. Di sisi lain, Deterministic Finite Automata (DFA) adalah model matematika yang berguna untuk merepresentasikan perilaku berurutan dan aturan transisi dalam bahasa formal. Dalam konteks penerjemah bahasa isyarat, DFA dapat dimanfaatkan untuk memvalidasi alur masukan atau struktur kata yang terbentuk dari hasil deteksi gestur untuk meningkatkan keandalan terjemahan [5].

Implementasi sistem berbasis *web* memungkinkan pengguna untuk mengakses layanan penerjemah bahasa isyarat langsung melalui *browser* di berbagai perangkat, baik komputer maupun ponsel pintar untuk meningkatkan aksesibilitas pengguna terkhusus bagi komunitas Tuli [6].

2. DASAR TEORI

2.1 Computer Vision

Computer Vision adalah cabang ilmu kecerdasan buatan yang memungkinkan komputer menganalisis dan memahami informasi dari citra atau video. Tujuan utama dari Computer Vision adalah meniru kemampuan sistem visual manusia dalam memproses dan menginterpretasikan informasi visual untuk menghasilkan keputusan atau tindakan yang berguna [7].

2.1.1 Peran Computer Vision

Computer Vision berperan sebagai mata sistem yang bertugas untuk:

- 1) Akuisisi Citra, berperan untuk mengambil dan memproses *frame* video dari kamera (*webcam*).
- 2) Deteksi Obyek (Tangan), berperan untuk mengidentifikasi dan melokalisasi keberadaan tangan manusia di dalam *frame*
- 3) Ekstraksi Fitur, setelah tangan terdeteksi, sistem mengekstraksi fitur kunci berupa koordinat titik-titik penting (*landmark*) pada sendi jari dan telapak tangan [8].


2.1.2 Tahapan Dasar Computer Vision

Secara umum, proses Computer Vision melibatkan beberapa tahapan utama:

- 1) *Pre-processing*, merupakan tahap awal yang meliputi normalisasi pencahayaan, penghilangan noise pada citra, dan segmentasi pemisahan obyek tangan dari latar belakang.
- 2) Segmentasi, proses membagi citra menjadi beberapa segmen untuk memfokuskan pemrosesan pada area yang relevan (tangan).
- 3) Representasi Fitur, proses mengubah data visual menjadi vektor fitur numerik yang dapat dipahami oleh model Deep Learning. Untuk sistem ini, outputnya adalah vektor koordinat *landmark*.
- 4) Klasifikasi, tahap di mana vektor fitur dimasukkan ke dalam model MLP untuk diklasifikasikan sebagai salah satu huruf ASL [8].

2.2 Deep Learning Multilayer Perceptron (MLP)

Deep Learning adalah subbidang dari pembelajaran *machine learning* yang fokus pada penggunaan jaringan syaraf tiruan yang dalam (*deep neural networks*) untuk mengekstraksi fitur dan memodelkan data yang kompleks. Deep Learning memanfaatkan arsitektur jaringan yang memiliki banyak lapisan (*deep layers*) untuk memahami representasi tingkat tinggi dari data, yang memungkinkan pemrosesan data yang sangat kompleks dan abstrak [9].




Gambar 1. Ilustrasi *deep neural networks*

Dalam sistem ini, Deep Learning berfungsi sebagai komponen utama yang bertugas mengenali dan mengklasifikasikan gerakan isyarat yang terekam dari pengguna[10]. Penerapan model Deep Learning terbukti efektif dalam klasifikasi citra, dengan tingkat akurasi sebesar 95,45% dalam mendeteksi isyarat SIBI [10]. Akurasi yang tinggi ini sangat penting karena hasil klasifikasi isyarat (misalnya urutan huruf) akan diteruskan dan divalidasi oleh Deterministic Finite Automata (DFA) pada tahap *post-processing* untuk memverifikasi konsistensi linguistik dan meningkatkan keandalan terjemahan secara keseluruhan.

2.2.1 Konsep Dasar Multilayer Perceptron (MLP)

Multilayer Perceptron (MLP) adalah salah satu arsitektur jaringan saraf tiruan yang paling fundamental dan paling sering digunakan untuk tugas klasifikasi dan regresi. Disebut Multilayer karena strukturnya terdiri dari beberapa lapisan yang terhubung secara penuh (*fully connected*). MLP tergolong sebagai salah satu model Deep Learning ketika memiliki satu atau lebih hidden layers di antara lapisan input dan output [11]. Dalam pengenalan bahasa isyarat, penerapan MLP berupaya memanfaatkan fitur-fitur yang berasal dari representasi geometri tangan untuk mempelajari pola hubungan antar titik pada gerakan isyarat. MLP tersusun atas lapisan-lapisan utama berikut:

- 1) Input Layer, berfungsi untuk menerima data masukan. Lapisan ini menerima vektor fitur numerik koordinat *landmark* tangan yang telah diekstraksi oleh Computer Vision.
- 2) Hidden Layer, lapisan di mana komputasi terjadi. Di lapisan ini, bobot (*weights*) dan bias disesuaikan selama proses pelatihan untuk menemukan pola kompleks yang tersembunyi dalam data.
- 3) Output Layer, berfungsi untuk menghasilkan hasil prediksi atau klasifikasi. Dalam kasus klasifikasi huruf ASL (A-Z), lapisan ini biasanya menggunakan fungsi aktivasi softmax untuk menghasilkan probabilitas bahwa masukan tersebut termasuk dalam salah satu dari 26 kelas[12].



Gambar 2. Ilustrasi Multilayer Perceptron (MLP)

2.2.1 Mekanisme Kerja MLP

Mekanisme kerja MLP pada sistem ini memproses data melalui beberapa lapisan neuron yang tersusun dalam alur satu arah. Setiap input akan dilalui ke lapisan berikutnya untuk menghasilkan output dengan bobot awalnya yang di tentukan secara acak. Pada proses pelatihan, jaringan akan berusaha memahami hubungan antara data masukan dan target keluarannya yang ada pada dataset. Nilai selisihnya yaitu nilai selisih antara prediksi model dan nilai target yang di hitung, lalu parameter yang berupa bobot dan bias di perbarui supaya kesalahan kesalahan tersebut semakin kecil. Penyesuaian ini di lanjutkan kembali ke lapisan lapisan yang sebelumnya melalui proses propagasi balik atau disebut juga dengan *backpropagation*.

Backpropagation berfungsi untuk memperbarui bobot dan bias dengan berdasarkan besar kecilnya kesalahan atau eror. Nilai kesalahan tersebut dapat di hitung dengan beberapa metode, salah satunya yaitu dengan *Root Mean Squared Error* (RMSE). MLP mampu menangani data yang tidak benar, memecahkan masalah dengan banyak variable, dan cocok untuk dataset yang besar dengan banyak fiturnya. Jaringan ini banyak di gunakan pada tugas supervised learning dan sistem yang membutuhkan proses paralel, contohnya pengenalan gambar, pengolahan suara, penerjemahan yang otomatis, dan berbagai jenis klasifikasi. [9] [13] .

2.3 Deterministic Finite Automata (DFA)

Deterministic Finite Automata (DFA) adalah model matematis yang paling sederhana dari Teori Bahasa Formal dan Otomata. DFA berfungsi sebagai mesin abstrak yang memiliki sejumlah keadaan (*state*) terbatas dan bergerak dari satu keadaan ke keadaan lain berdasarkan input yang diterima. Model ini bersifat deterministik, artinya untuk setiap pasangan state dan input yang diberikan, selalu terdapat tepat satu transisi ke state berikutnya. Secara formal, DFA didefinisikan sebagai 5 tuple $(Q, \Sigma, \delta, q_0, F)$, di mana:

- 1) Q adalah himpunan keadaan (*states*) yang terbatas.
- 2) Σ adalah alfabet, yaitu himpunan simbol- simbol masukan.
- 3) δ adalah fungsi transisi, yaitu fungsi $\delta: Q \times \Sigma \rightarrow Q$ yang menghubungkan keadaan- keadaan dalam Q dengan simbol-simbol dalam Σ .
- 4) q_0 adalah keadaan awal (*start state*), yaitu $q_0 \in Q$.
- 5) F adalah himpunan keadaan akhir (*final states*), yaitu $F \subseteq Q$.

DFA membaca simbol-simbol dari alfabet Σ satu per satu, memulai dari keadaan awal q_0 , dan bergerak dari satu keadaan ke keadaan lain berdasarkan fungsi transisi δ . Setelah DFA selesai membaca seluruh masukan, DFA akan berada pada salah satu keadaan. Jika keadaan tersebut adalah keadaan akhir (F), maka DFA mengenali masukan sebagai bahasa formal tertentu. Jika tidak, maka DFA tidak mengenali masukan tersebut [5][14] .

Dalam sistem penerjemah bahasa isyarat yang menggunakan model probabilistik seperti Multilayer Perceptron (MLP), output yang dihasilkan cenderung rentan terhadap ketidakstabilan yang terjadi karena MLP melakukan klasifikasi pada setiap frame video secara independen. Akibatnya, satu isyarat tangan yang statis bisa terbaca sebagai urutan acak jika tangan sedikit bergerak. DFA diimplementasikan untuk mengatasi masalah ini dengan berfungsi sebagai filter logika dan validator urutan yang ketat seperti validasi transisi dan ejaan ASL untuk membentuk sebuah kata.


2.4 American Sign Language

American Sign Language (ASL) adalah bahasa isyarat yang digunakan secara luas oleh komunitas Tuli di Amerika Serikat dan hampir digunakan oleh berbagai negara di seluruh dunia [1] . Berikut merupakan kamus American Sign Language:

SIGN LANGUAGE NUMBERS



American Sign Language Alphabet



Copyright © 2008 StartASL.com

Gambar 3. American Sign Language

Dalam sistem penerjemah bahasa isyarat ini, fokus utama ada pada *fingerspelling* ASL. *Fingerspelling* adalah teknik pengejaan kata-kata menggunakan isyarat satu tangan yang merepresentasikan setiap huruf alfabet. Teknik ini digunakan terutama untuk mengeja nama orang, nama tempat, atau kata-kata teknis yang tidak memiliki isyarat tunggal.

3. PEMBAHASAN

3.1 Dataset American Sign Language

Dataset ASL Alphabet *Hand Gesture* adalah kumpulan komprehensif citra gestur tangan yang dirancang untuk melatih model Deep Learning untuk pengenalan ASL secara real-time. Dataset ini meningkatkan model computer vision dengan memungkinkan klasifikasi yang akurat terhadap gestur huruf alfabet ASL, sehingga mendukung sistem interpretasi bahasa isyarat *real-time*. Dataset ini terdiri dari 100-300 gambar per satu huruf atau angka, yang menangkap variasi gestur tangan dalam berbagai kondisi untuk meningkatkan kemampuan generalisasi model. Kondisi tersebut meliputi:

- 1) Lingkungan pencahayaan berbeda: terang, redup, dan bayangan.
- 2) Latar belakang bervariasi
- 3) Berbagai sudut pandang dan orientasi tangan untuk ketahanan model.

Setiap gambar diberi anotasi dengan 21 titik kunci (*keypoints*), yang secara akurat menandai struktur penting tangan seperti ujung jari (*fingertips*), buku jari (*knuckles*), dan pergelangan (*wrist*). Anotasi ini menyediakan representasi rangka tangan, sehingga memungkinkan model membedakan gestur yang serupa dengan tingkat ketelitian yang lebih tinggi [2].



Gambar 4. Dataset American Sign Language

3.2 Kinerja Model Deep Learning dalam Klasifikasi Citra

Kinerja model *Multilayer Perceptron (MLP)* dalam mengklasifikasikan gestur tangan American Sign Language (ASL) dianalisis berdasarkan vektor fitur *landmark* yang dihasilkan oleh Mediapipe Hands. Evaluasi dilakukan menggunakan data uji yang tidak disertakan selama proses pelatihan untuk menilai kemampuan generalisasi model dalam mengenali gestur baru. Analisis performa mencakup akurasi, presisi, recall, *F1-score*, kestabilan proses pelatihan, serta pemeriksaan detail melalui *confusion matrix* untuk melihat pola kesalahan klasifikasi pada setiap kelas.

3.2.1 Analisis Metrik Evaluasi Model

Evaluasi performa dilakukan menggunakan metrik standar, yaitu *Accuracy*, *Precision*, *Recall*, dan *F1-Score*. Nilai-nilai ini memberikan gambaran menyeluruh mengenai kemampuan model dalam menghasilkan prediksi yang benar dan konsisten pada berbagai kelas isyarat.

Untuk melakukan evaluasi performa model, perlu uji coba model berkali-kali untuk mendapatkan data tebakan benar dan salah yang dihasilkan oleh model dan kemudian dihitung untuk mendapatkan nilai *accuracy*, *precision*, *recall*, dan *F1-score*. Berikut merupakan formula untuk mendapatkan nilai-nilai tersebut.

- $Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$
- $Precision = \frac{TP}{TP + FP}$
- $Recall = \frac{TP}{TP + FN}$
- $F1 - Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$

Nilai *True Positive* (TP) adalah berapa kali model memprediksi 'Yes' dan hasilnya memang benar/positif ('Yes'). Sebaliknya dengan TP, nilai *True Negative* (TN) yaitu berapa kali model memprediksi 'No' dan hasilnya adalah memang salah/negatif ('No'). Sedangkan

False Positive (FP) dan *False Negative* (FN) adalah kebalikan dari TP dan TN, yaitu ketika tebakan dan hasilnya berbanding terbalik [15].

Pada model yang dikembangkan, diperkirakan dapat menghasilkan nilai *accuracy*, *precision*, *recall*, dan *F1-Score* $\geq 90\%$ yang menunjukkan bahwa model mampu mengklasifikasikan sebagian besar gestur dengan baik. MLP efektif digunakan pada data berdimensi tetap seperti vektor *landmark*. Nilai presisi dan recall yang seimbang juga akan menghasilkan *F1-score* tinggi, mengindikasikan bahwa model tidak hanya akurat dalam memprediksi kelas yang benar tetapi juga mampu menangkap sebagian besar sampel positif yang ada [16], juga efektivitas representasi landmark dalam membedakan pola tangan yang kompleks [4].

3.2.2 Analisis *Overfitting*

Jika proses pelatihan menunjukkan bahwa *training accuracy* dan *validation accuracy* meningkat secara stabil, maka selisih nilai akurasi pelatihan dan validasi terbilang kecil sehingga hal itu menandakan bahwa model tidak mengalami *overfitting* secara signifikan. Hal tersebut juga menandakan bahwa model mampu mempelajari pola penting dari data. Jaringan saraf tiruan berbasis backpropagation menunjukkan performa stabil ketika data input memiliki representasi fitur yang konsisten, seperti vektor *landmark* dari Mediapipe. Dengan stabilitas tersebut, model menjadi lebih siap diimplementasikan secara *real-time* berbasis web [17].

3.2.3 Implikasi terhadap Integrasi dengan DFA

Walaupun MLP menunjukkan performa tinggi, beberapa kesalahan klasifikasi tetap terjadi pada gestur dengan kemiripan struktur tangan. Keterbatasan ini menunjukkan pentingnya integrasi dengan Deterministic Finite Automata (DFA) sebagai lapisan logika tambahan. DFA berperan memastikan bahwa urutan huruf yang dihasilkan model membentuk kata yang valid dan sesuai kaidah linguistik. Dengan demikian, DFA membantu mengoreksi potensi noise dari prediksi MLP, sehingga sistem penerjemah bahasa isyarat yang dibangun dapat memberikan interpretasi yang lebih akurat [5] [11].

3.3 Integrasi Model Deep Learning dengan DFA

Integrasi antara model Deep Learning dan Deterministic Finite Automata (DFA) memadukan kemampuan pemodelan pola kompleks dari jaringan saraf dengan ketegasan aturan logika formal pada DFA. Integrasi antara model Deep Learning Multilayer Perceptron (MLP) yang bersifat probabilistik dan sistem logika Deterministic Finite Automata (DFA) yang bersifat deterministik bertujuan utama untuk mengatasi masalah ketidakstabilan output (flickering) yang dihasilkan oleh klasifikasi *frame-per-frame* MLP, serta memastikan validitas urutan huruf menjadi kata yang sah.

Deep learning bertanggung jawab pada level pengenalan (*recognition level*), sedangkan DFA menangani level interpretasi (*interpretation level*). Dengan kata lain, hasil klasifikasi gestur tunggal tidak langsung diterjemahkan menjadi output kalimat, tetapi disusun terlebih dahulu menggunakan aturan urutan simbol yang layak menurut DFA. Pendekatan ini mengurangi kemungkinan kesalahan interpretasi ketika pengguna melakukan gestur secara berurutan, karena DFA memastikan bahwa setiap transisi berada pada jalur yang valid.

Selain meningkatkan validitas interpretasi, integrasi ini juga memberikan keuntungan pada sisi skalabilitas sistem. Deep learning menangani variasi visual seperti orientasi tangan, pencahayaan, dan latar belakang, sedangkan DFA menangani aspek tata bahasa (grammar) sederhana yang dibutuhkan sistem. Misalnya, jika model deep learning mengklasifikasikan gestur menjadi huruf alfabet ASL, DFA akan menentukan apakah urutan huruf tersebut membentuk kata yang valid atau memerlukan state revisi sebelum validasi akhir. Sehingga hasil akhirnya tidak hanya akurat secara visual, tetapi juga bermakna secara linguistik [11].

3.4 Implementasi Sistem

Implementasi sistem penerjemah huruf dan angka individual ASL ke dalam bentuk output tampilan pada layar yang berbasis web mengintegrasikan *Computer Vision* (CV) untuk deteksi gestur tangan melalui kamera *user*, model *Deep Learning Multilayer Perceptron* (MLP) yang membantu keakuratan klasifikasi dalam menerjemahkan gestur ke dalam bentuk output print pada layar, serta

Deterministic Finite Automata (DFA) untuk memvalidasi urutan terjemahan. Sistem dikembangkan menggunakan arsitektur *client-server architecture*, yaitu *Computer Vision* (CV) dan klasifikasi MLP berjalan di browser pengguna untuk pemrosesan secara *real-time*, sedangkan logika DFA dan pengelolaan *database* kata kamus berada di server.

3.4.1 Arsitektur Sistem

3.4.1.1 Frontend



Gambar 5. Tampilan Beranda Website




Gambar 6. Tampilan Terjemahan Website

Pada lapisan ini sistem berisikan frame video menggunakan *webcam* dari pengguna untuk menangkap video secara *real-time*. Dari video yang ditangkap, nantinya akan menampilkan titik kunci pada jari yang ditunjukkan pada kamera (*webcam*) pengguna. Kemudian titik kunci tersebut dimasukkan ke dalam model MLP yang telah dilatih menggunakan dataset yang telah dikumpulkan pada saat *model training* untuk menghasilkan prediksi terhadap 26 huruf alfabet dan 9 angka ASL.

3.4.1.2 Backend

Output klasifikasi MLP diteruskan ke server yang selanjutnya akan melalui proses validasi urutan huruf mesin DFA berdasarkan kamus kata yang telah ditentukan. DFA memastikan bahwa huruf-huruf yang diterima membentuk string yang diakui sebagai kata yang sah. Kata-kata yang sah tersebut merupakan kata yang telah disimpan dalam basis data web.

3.4.2 Implementasi DFA pada Sistem



Gambar 7. DFA pada Sistem

Deterministic Finite Automata (DFA) pada sistem ini digunakan sebagai mekanisme validasi urutan kata atau huruf dari hasil klasifikasi gestur tangan pada sistem penerjemahan American Sign Language (ASL) berbasis web. DFA disini berperan memastikan urutan huruf yang di hasilkan oleh model Multilayer Perceptron (MLP) membentuk kata yang benar dengan kamus yang di tentukan. Dengan diagram DFA pada gambar.5, sistem memiliki satu state awal q0 dan dua state akhir q4 dan q6 yang masing masing menunjukkan kata “BACA” dan “BATU”. Proses validasi ini dimulai ketika huruf dari hasil klasifikasi MLP di terima secara terstruktur dan berurutan, dimulai dari huruf ‘B’ menuju state q1, lalu huruf ‘A’ ke state q2, kemudia memiliki dua cabang sesuai karakter berikutnya hingga ke state akhir. Apabila urutan karakternya tidak sesuai dengan yang di definisikan, maka DFA tidak akan mencapai state akhir tersebut dan dianggap tidak benar. Dengan menggunakan DFA ini, sistem dapat meningkatkan keakuratan hasil terjemahan pada huruf atau kata dan memastikan hanya huruf atau kata yang sesuai dengan kamus yang di tampilkan kepada pengguna.

3.4.3 Alur Kerja Sistem

1. Input kamera menangkap video isyarat tangan ASL.
2. Setiap landmark diekstraksi dan diklasifikasikan oleh MLP. Kemudian dihasilkan prediksi huruf ASL.
3. Huruf ASL yang terkonfirmasi dikirimkan ke server.
4. Server memproses urutan huruf yang masuk dengan memverifikasi transisi dari satu *state* ke *state* selanjutnya. Jika urutan mencapai *final state* dalam kamu DFA, maka urutan huruf tersebut terkonfirmasi sebagai sebuah kata yang valid.
5. Kata yang tervalidasi ditampilkan pada kolom terjemahan.

3.5 Efektivitas Algoritma

Dari sisi pengenalan citra, penggunaan arsitektur Multilayer Perceptron (MLP) menjadi efektif apabila input telah melalui tahap ekstraksi fitur sehingga representasi numeriknya cukup informatif. Efektivitas ini tercermin pada tingkat akurasi klasifikasi yang stabil meskipun citra mengalami perbedaan latar, sudut, atau pencahayaan. Adapun dari sisi integrasi, DFA memberikan efek peningkatan efektivitas sistem karena berfungsi sebagai penyaring hasil klasifikasi. Deep learning mampu mengenali gestur, tetapi tidak memahami struktur bahasa. DFA mengisi celah ini dengan aturan transisi sehingga keluaran menjadi konsisten secara linguistik. Hal ini menjadikan keseluruhan sistem lebih efektif dibanding menggunakan Deep Learning saja. Dengan adanya DFA, sistem lebih tahan terhadap kesalahan input yang berurutan dan mampu mengurangi *noise* interpretasi, terutama dalam komunikasi *real-time* [11] [14]

4. KESIMPULAN

Pengembangan penerjemahan bahasa isyarat dasar berbasis *web* dengan memanfaatkan kombinasi *deep learning Multilayer Perceptron* (MLP) dan *Deterministic Finite Automata* (DFA) dibuat untuk membangun kerangka kerja yang dapat mengenali gestur tangan secara digital dengan memproses citra, deteksi dan pembacaan titik *landmark* dan pengelompokan pola menggunakan MLP. Penggabungan DFA di tempatkan sebagai proses sebelum pengolahan yang bertujuan untuk membentuk sistem pemeriksaan urutan simbol agar output penerjemahannya bisa lebih terstruktur dan mengurangi gangguan pada hasil prediksi dan menjaga agar huruf atau kata yang di hasilkan bisa baik, benar dan konsisten. *Platform* berbasis *web* ini di pilih agar memberikan akses yang lebih mudah, supaya sistem dapat di jalankan di berbagai perangkat tanpa instalasi tambahan. Pendekatan ini juga dapat membuka peluang agar menjadi media pembelajaran dan alat komunikasi bagi pengguna bahasa isyarat.

5. DAFTAR PUSTAKA

- [1] A. Rudiyanto, Y. Azhar, and K. Kunci, "Pengenalan Sistem Isyarat Bahasa Indonesia (SIBI) Menggunakan Arsitektur Mobilenet," *REPOSITOR*, vol. 6, no. 4, pp. 425–432, 2024.
- [2] B. Alsharif, E. Alalwany, A. Ibrahim, I. Mahgoub, and M. Ilyas, "Real-Time American Sign Language Interpretation Using Deep Learning and Keypoint Tracking," *Sensors*, vol. 25, no. 7, Apr. 2025, doi: 10.3390/s25072138.
- [3] I. Bagus *et al.*, "3520 <https://ejournal.sidyanusa.org/index.php/jkdn> Deteksi Bahasa Isyarat Menggunakan Tensorflow Lite dan American Sign Language (ASL)," 2023. [Online]. Available: <https://ejournal.sidyanusa.org/index.php/jkdn>
- [4] K. Feny Sugiantari, P. Hendra Suputra, L. Joni Erawati Dewi, G. Bakti Pratama Putra, and K. Kunci Klasifikasi, "PENDEKATAN MLP DALAM KLASIFIKASI BAHASA ISYARAT: ANALISIS JARAK EUCLIDEAN LANDMARK TANGAN," 2025.
- [5] J. Sistem Komputer dan Kecerdasan Buatan *et al.*, "Simulator Mesin Deterministic Finite Automata (DFA) Berdasarkan Diagram Transisi Menggunakan Python."
- [6] S. Irviantina, D. A. Wijaya, D. R. Situmorang, N. Mawaddah, and J. Nasution, "[371 DETEKSI BAHASA ISYARAT BERDASARKAN ABJAD MENGGUNAKAN METODE LSTM (LONG SHORT-TERM MEMORY)," vol. 14, no. 3, pp. 371–376, doi: 10.46880/methoda.Vol14No3.pp371-376.
- [7] M. Arif *et al.*, "Biner : Jurnal Ilmu Komputer, Teknik dan Multimedia Sistem Pendeteksi Tangan Berbasis Mediapipe Dan OpenCV Untuk Pengenalan Gerakan," 2024. [Online]. Available: <https://journal.mediapublikasi.id/index.php/Biner>
- [8] S. N. Budiman, S. Lestanti, H. Yuana, and B. N. Awwalin, "Jurnal Teknologi dan Manajemen Informatika SIBI (Sistem Bahasa Isyarat Indonesia) berbasis Machine Learning dan Computer Vision untuk Membantu Komunikasi Tuna Rungu dan Tuna Wicara," vol. 9, no. 2, pp. 119–128, 2023, [Online]. Available: <http://http://jurnal.unmer.ac.id/index.php/jtmi>
- [9] "Klasifikasi Alfabet Sistem Isyarat Bahasa Indonesia (SIBI) Menggunakan Computer Vision dan Deep Learning."
- [10] F. Pratama *et al.*, "MODEL DEEP LEARNING UNTUK PENERJEMAH BAHASA ISYARAT SIBI DENGAN ARSITEKTUR TRANSFER LEARNING," *Journal of Digital Business and Technology Innovation (DBESTI)*, vol. 2, no. 1, pp. 133–139, 2025, [Online]. Available: <https://journal.nurulfikri.ac.id/index.php/DBESTI>
- [11] A. H. A. Abdel-aziem and T. H. M. Soliman, "A Multi-Layer Perceptron (MLP) Neural Networks for Stellar Classification: A Review of Methods and Results," *International Journal of Advances in Applied Computational Intelligence*, vol. 1, no. 2, pp. 29–37, 2023, doi: 10.54216/IJAACI.030203.
- [12] K. Feny Sugiantari, P. Hendra Suputra, L. Joni Erawati Dewi, G. Bakti Pratama Putra, and K. Kunci Klasifikasi, "PENDEKATAN MLP DALAM KLASIFIKASI BAHASA ISYARAT: ANALISIS JARAK EUCLIDEAN LANDMARK TANGAN," 2025.

-
- [13] P. Agung Nugroho, "IMPLEMENTASI JARINGAN SYARAF TIRUAN MULTI-LAYER PERCEPTRON UNTUK PREDIKSI PENYINARAN MATAHARI KOTA BANDUNG," *KOMPUTA: Jurnal Ilmiah Komputer dan Informatika*, vol. 12, no. 1, 2023.
 - [14] A. Gazali Sati, M. Dwiki Wicaksono, R. Farhan Saputra, and T. Setiadi, "Analisis Dan Implementasi Finite State Automata Pada Sistem Vending Machine." [Online].
 - [15] O. Rainio, J. Teuho, and R. Klén, "Evaluation metrics and statistical tests for machine learning," *Sci Rep*, vol. 14, no. 1, Dec. 2024, doi: 10.1038/s41598-024-56706-x.
 - [16] S. H. Gulo and A. H. Lubis, "Penerapan Multi-Layer Perceptron untuk Mengklasifikasi Penduduk Kurang Mampu," 2024.
 - [17] S. Hence and D. Loppies, "IMPLEMENTASI JARINGAN SARAF TIRUAN BACKPROPAGATION UNTUK DETEKSI WAJAH DALAM CITRA DIGITAL," 2018.

6. SURAT PERNYATAAN

PERNYATAAN

Dengan ini kami menyatakan artikel yang kami tulis ini adalah karya kami sendiri, bukan saduran, atau terjemahan dari makalah orang lain, dan bukan plagiasi.

Bandung, 10 November 2025



Farid Fathurrahman Hakim